عنوان پروژه:

Sentiment Analysis

استاد محترم:

دکتر جعفر رزم‌آرا

تهیه کننده:

امید نجاتی

986321027

بهار 1402

فهرست:

1.صورت مسئله پروژه

تعیین قطبیت متون، فرآیند تحلیل نظرات، کاربران است که از مستندات موجود در یک موضوع خاص استخراج می شود (نظرات یک فیلم، توییت های توییتر، نظرات سایت آمازون و ...). هدف این پروژه، تعیین قطبیت (مثبت، منفی و خنثی) متون انگلیسی است.

2.الگوریتم و نحوه حل مسئله

روش حل مسئله مورد استفاده در این کد را می توان به عنوان یک رویکرد یادگیری نظارت شده توصیف کرد، که در آن یک مدل یادگیری ماشینی بر روی داده های برچسب گذاری شده (بازبینی هایی که به عنوان مثبت یا منفی برچسب گذاری شده اند) آموزش داده می شود تا احساسات نظرات جدید و دیده نشده را پیش بینی کند. تکنیک‌های NLP مورد استفاده در این کد، مانند پیش‌پردازش داده‌ها و استخراج ویژگی‌ها، رویکردهای رایجی هستند که برای آماده‌سازی داده‌های متنی برای وظایف یادگیری ماشین استفاده می‌شوند.

3. دیتاست

با استفاده از web crawler از توییتر گردآوری شده است و پیش پردازش هایی بر روی این داده ها انجام شده و سپس در فایل به فرمت csv ذخیره شده است.

دیتاست جمع آوری شده شامل 31015 نظر می باشد. این دیتاست شامل متن نظر، برچسب های مثبت، منفی یا خنثی می باشد. برچسب های این داده ها با استفاده از امتیازات ثبت شده همراه نظرات استخراج شده است، داده‌های معرفی شده غیر متعادل بوده است و داده ها با برچسب مثبت مقداری بیشتر از منفی است و برچسب خنثی از مثبت هم بیشتر است. توزیع داده ها به صورت زیر است:

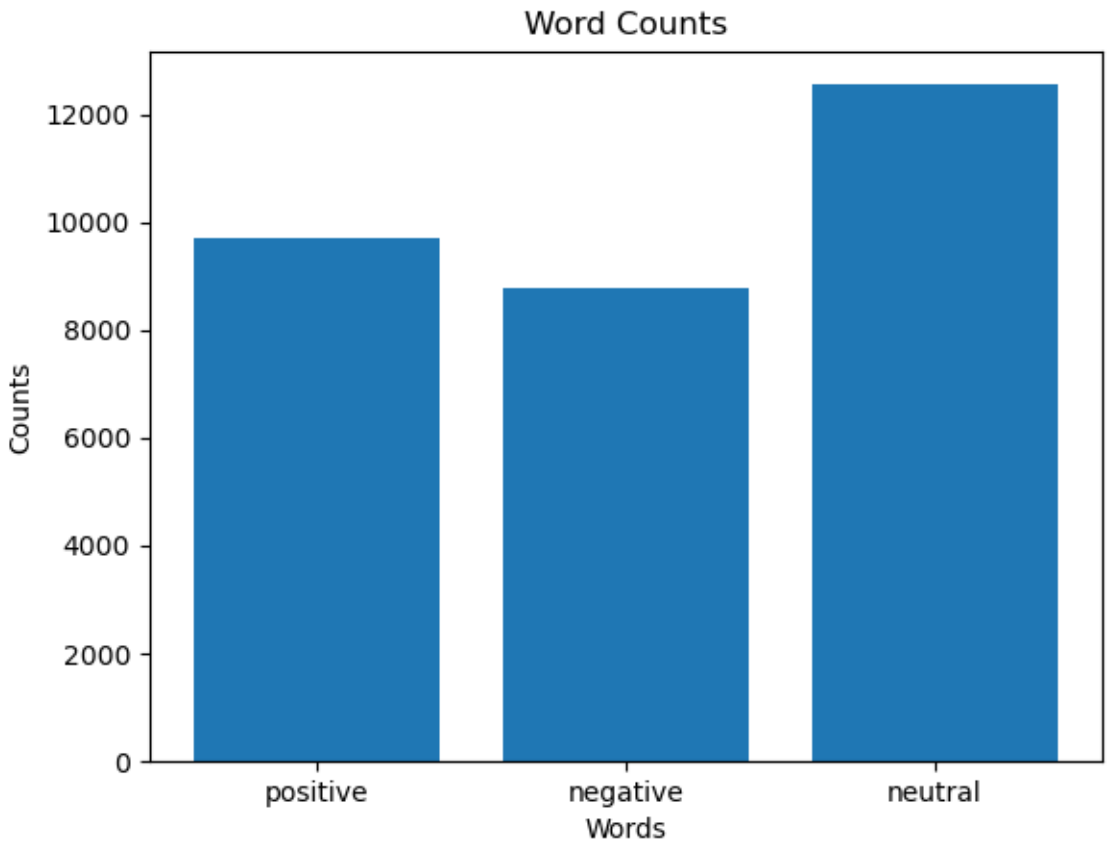

	textID	text	selected_text	sentiment
0	cb774db0d1	I`d have responded, if I were going	I`d have responded, if I were going	neutral
1	549e992a42	Sooo SAD I will miss you here in San Diego!!!	Sooo SAD	negative
2	088c60f138	my boss is bullying me...	bullying me	negative
3	9642c003ef	what interview! leave me alone	leave me alone	negative
4	358bd9e861	Sons of ****, why couldn`t they put them on t...	Sons of ****,	negative

4. کار های انجام شده

4.1. پیش‌پردازش داده:

گام اول، پیش‌پردازش داده است. این شامل بارگیری مجموعه داده در حافظه، انتخاب ستون‌های مربوطه و تبدیل متغیرهای طبقه‌بندی شده به مقادیر عددی است. در این کد، مجموعه داده از یک فایل CSV با استفاده از کتابخانه Pandas بارگیری می‌شود. ستون‌های مربوط به تحلیل احساس (متن و احساس) انتخاب می‌شوند و برچسب‌های احساسی با استفاده از یک دیکشنری به صورت رشته‌ای (منفی=0، بی‌طرف=1، مثبت=2) تبدیل می‌شوند.

```
sentiment_dict = {'negative': 0, 'neutral': 1, 'positive': 2}
tweet_df['sentiment'] = tweet_df['sentiment'].map(sentiment_dict)

sentiment_dict
```

```
{'negative': 0, 'neutral': 1, 'positive': 2}
```

```
tweet_df["sentiment"].value_counts()
```

```
1 12547

2 9685

0 8782
```

4.2. پیش‌پردازش متن:

4.2.1. توکن‌بندی داده‌های متنی:

داده‌های متنی در ستون 'text' از جدول داده به کمک کلاس Tokenizer از کتابخانه TensorFlow توکن‌بندی می‌شوند. توکن‌بندی‌کننده (Tokenizer) هر کلمه را در متن به یک مقدار عددی تبدیل می‌کند. حداکثر تعداد کلماتی که نگه داشته می‌شود را 5000 تعیین

می‌کند و با استفاده از متد fit_on_texts()، توکن‌بندی‌کننده بر روی داده‌های متنی تنظیم می‌شود. توکن‌بندی‌کننده یک شاخص عددی منحصربفرد به هر کلمه بر اساس فراوانی تکرار آن در داده‌های متنی اختصاص می‌دهد.

4.2.2. پرکردن داده‌های متنی:

بعد از توکن‌بندی، داده‌های متنی برای اطمینان از اینکه تمام دنباله‌ها دارای طول یکسان باشند، پر می‌شوند. برای پرکردن دنباله‌ها، از تابع pad_sequences() کتابخانه TensorFlow استفاده می‌شود. encoded_docs که از مرحله قبل به دست آمده است، به عنوان ورودی به تابع pad_sequences() داده می‌شود و پارامتر maxlen به مقدار 200 تنظیم می‌شود که نشان دهنده آن است که تمام دنباله‌ها به طول 200 پر یا قطع می‌شوند.

```
# Tokenize text data
tweet = tweet_df.text.values
tokenizer = Tokenizer(num_words=5000)
tokenizer.fit_on_texts(tweet.astype('str'))
vocab_size = len(tokenizer.word_index) + 1
encoded_docs = tokenizer.texts_to_sequences(tweet.astype('str'))
padded_sequence = pad_sequences(encoded_docs, maxlen=200)
print(tokenizer.word_index)
```

```
{'i': 1, 'to': 2, 'the': 3, 'a': 4, 'my': 5, 'it': 6, 'you': 7, 'and': 8, 'is': 9, 'in': 10, 's': 11,…}
```

```
print(tweet[0])
print(encoded_docs[0])
```

```
I`d have responded, if I were going
[1, 162, 19, 71, 1, 151, 49]
```

```
print(padded_sequence[0])
```

```
[  0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
```

```
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
   0   0   0   0   0   0   0   0   0   0   0   0   0   1 162  19  71   1
 151  49]
```

4.3. تقسیم داده:

داده به دو مجموعه آموزش و آزمون با استفاده از تابع train_test_split() از کتابخانه scikit-learn تقسیم می‌شود. دنباله‌های پرکرده (padded_sequence) و برچسب‌های احساس (tweet_df['sentiment']) به دو مجموعه آموزش و آزمون تقسیم می‌شوند، با نسبت آزمون 20٪ و یک حالت تصادفی (random state) با مقدار 42. مجموعه آموزش به train_x و train_y اختصاص داده می‌شود و مجموعه آزمون به test_x و test_y اختصاص داده می‌شود.

```
# Split data into training and testing sets
train_x, test_x, train_y, test_y = train_test_split(padded_sequence,
tweet_df['sentiment'], test_size=0.2, random_state=42)
```

5. تعریف مدل:

معماری مدل LSTM با استفاده از مدل Sequential از Keras تعریف می‌شود. مدل شامل لایه Embedding، لایه SpatialDropout1D، لایه LSTM با 128 واحد و لایه Dense با 3 واحد است. لایه Embedding هر کلمه در دنباله ورودی را به یک فضای برداری بُعد بالا نگاشت می‌دهد. لایه SpatialDropout1D به صورت تصادفی بخش‌های کامل ویژگی‌های 1D را در لایه Embedding حذف می‌کند تا از اورفیتینگ جلوگیری شود. لایه LSTM نوعی از شبکه عصبی بازگشتی است که به ویژه برای داده‌های دنباله‌ای کارآمد است. لایه Dense برچسب احساس پیش‌بینی شده را برای هر ورودی خروجی می‌دهد.

```
# Define the model architecture
embedding_vector_length = 32
model = Sequential()
```

```
model.add(Embedding(vocab_size, embedding_vector_length,
input_length=200))
model.add(SpatialDropout1D(0.4))
model.add(LSTM(128, dropout=0.4, recurrent_dropout=0.4))
model.add(Dense(3, activation='softmax'))
```

بطور کلی، این کد ساختار مدل تحلیل احساسات با استفاده از روش‌های یادگیری عمیق را تعریف می‌کند. از مدل Sequential در TensorFlow استفاده شده است که امکان اضافه کردن لایه‌ها به صورت پشت سر هم را فراهم می‌کند.

ساختار مدل شامل چند لایه است:

5.1. لایه Embedding: این لایه کلمات را به بردارهای چگال با اندازه ثابت تبدیل می‌کند. با نمایش کلمات در یک فضای برداری پیوسته، معنای معنایی کلمات را به خوبی درک می‌کند.

5.2. لایه SpatialDropout1D: این لایه به صورت تصادفی عناصر را از لایه قبلی حذف می‌کند تا از بیش‌برازش جلوگیری کند. با کاهش وابستگی به ویژگی‌های خاص، به تعمیم‌پذیری مدل کمک می‌کند.

5.3. لایه LSTM: لایه LSTM یک نوع لایه شبکه عصبی بازگشتی (RNN) است که به خوبی داده‌های دنباله‌ای را پردازش می‌کند. این لایه وابستگی‌های زمانی در متن را ضبط می‌کند و به درک زمینه کمک می‌کند.

5.4. لایه Dense: این لایه یک لایه کاملاً متصل است که عملیات طبقه‌بندی را انجام می‌دهد. ویژگی‌هایی که توسط لایه‌های قبلی یادگرفته شده‌اند را به کلاس‌های

خروجی نگاشت می‌دهد. در این حالت، ۳ نرون که مربوط به کلاس‌های احساسی منفی، خنثی و مثبت هستند، وجود دارد. تابع فعال‌سازی softmax برای به دست آوردن احتمال برای هر کلاس استفاده می‌شود.

این ساختار مدل به مدل امکان یادگیری نمایش‌های معنادار از کلمات، درک اطلاعات زمینه‌ای و طبقه‌بندی احساسات داده‌های متنی را می‌دهد.

6. کامپایل مدل:

مدل با استفاده از متد compile() کامپایل می‌شود. این متد شامل تابع خطا، بهینه‌ساز و معیارهای استفاده شده در طول آموزش و ارزیابی است. در این کد، تابع خطا sparse_categorical_crossentropy استفاده می‌شود که برای مسائل طبقه‌بندی چند دسته‌ای مانند تحلیل احساس مناسب است. بهینه‌ساز استفاده شده Adam است که یک بهینه‌ساز محبوب برای مدل‌های یادگیری عمیق است با نرخ یادگیری 0.0001. معیارهای استفاده شده برای ارزیابی مدل، دقت است که نسبت نمونه‌های صحیحاً دسته‌بندی شده را مشخص می‌کند.

```
# Define the model architecture

embedding_vector_length = 32
model = Sequential()
model.add(Embedding(vocab_size, embedding_vector_length,
input_length=200))
model.add(SpatialDropout1D(0.4))
model.add(LSTM(128, dropout=0.4, recurrent_dropout=0.4))
model.add(Dense(3, activation='softmax'))

# Define the optimizer with a lower learning rate
optimizer = Adam(learning_rate=0.0001)
# Compile the model with the new optimizer
model.compile(loss='sparse_categorical_crossentropy', optimizer=optimizer,
metrics=['accuracy'])
```

7. توقف زودهنگام:

برای جلوگیری از اورفیت و بهبود توانایی تعمیم مدل، از توقف زودهنگام به عنوان یک بازخوانی در طول آموزش استفاده می‌شود. بازخوانی EarlyStopping() هنگام آموزش ضرر اعتبارسنجی را نظارت می‌کند و در صورت بهبود نداشتن ضرر اعتبارسنجی برای تعداد مشخصی از دوره‌ها (در این مورد 3) آموزش را متوقف می‌کند.

```
# Define early stopping callback
earlystop = EarlyStopping(monitor='val_loss', min_delta=0, patience=3,
verbose=0, mode='auto')
```

8. آموزش مدل:

مدل با استفاده از متد fit() بر روی داده‌های آموزش آموزش داده می‌شود. در طول آموزش، مدل سعی می‌کند تا تابع خطا را کمینه کند، با تنظیم وزن‌های مدل با استفاده از پس‌انتشار خطا. اندازه دسته تنظیم شده برابر با 64 است، به این معنی که مدل هر بار بر روی 64 نمونه آموزش می‌بیند. تعداد دوره‌ها تنظیم شده برابر با 20 است که به این معنی است که مدل بر روی تمام مجموعه آموزش 20 بار آموزش دیده است.

```
# Fit the model
history = model.fit(train_x, train_y, validation_data=(test_x, test_y),
epochs=20, batch_size=64, callbacks=[earlystop])
```

```
Epoch 1/20
388/388 [==============================] - 285s 736ms/step - loss: 0.7126 - accuracy: 0.6922 - val_loss: 0.7137 - val_accuracy: 0.6889
Epoch 2/20
388/388 [==============================] - 295s 760ms/step - loss: 0.6958 - accuracy: 0.7044 - val_loss: 0.7065 - val_accuracy: 0.6998
Epoch 3/20
388/388 [==============================] - 294s 759ms/step - loss: 0.6790 - accuracy: 0.7161 - val_loss: 0.6990 - val_accuracy: 0.6974
Epoch 4/20
388/388 [==============================] - 305s 786ms/step - loss: 0.6653 - accuracy: 0.7211 - val_loss: 0.6916 - val_accuracy: 0.7027
Epoch 5/20
388/388 [==============================] - 284s 733ms/step - loss: 0.6561 - accuracy: 0.7244 - val_loss: 0.6861 - val_accuracy: 0.7101
Epoch 6/20
388/388 [==============================] - 297s 767ms/step - loss: 0.6450 - accuracy: 0.7308 - val_loss: 0.6816 - val_accuracy: 0.7119
Epoch 7/20
388/388 [==============================] - 294s 757ms/step - loss: 0.6327 - accuracy: 0.7385 - val_loss: 0.6847 - val_accuracy: 0.7098
Epoch 8/20
388/388 [==============================] - 279s 717ms/step - loss: 0.6281 - accuracy: 0.7413 - val_loss: 0.6780 - val_accuracy: 0.7155
Epoch 9/20
388/388 [==============================] - 278s 717ms/step - loss: 0.6187 - accuracy: 0.7458 - val_loss: 0.6764 - val_accuracy: 0.7164
Epoch 10/20
388/388 [==============================] - 290s 747ms/step - loss: 0.6145 - accuracy: 0.7472 - val_loss: 0.6786 - val_accuracy: 0.7155
Epoch 11/20
388/388 [==============================] - 293s 753ms/step - loss: 0.6070 - accuracy: 0.7547 - val_loss: 0.6752 - val_accuracy: 0.7169
Epoch 12/20
388/388 [==============================] - 294s 757ms/step - loss: 0.5999 - accuracy: 0.7547 - val_loss: 0.6744 - val_accuracy: 0.7193
Epoch 13/20
388/388 [==============================] - 296s 762ms/step - loss: 0.5918 - accuracy: 0.7600 - val_loss: 0.6747 - val_accuracy: 0.7187
Epoch 14/20
388/388 [==============================] - 291s 751ms/step - loss: 0.5898 - accuracy: 0.7587 - val_loss: 0.6732 - val_accuracy: 0.7211
Epoch 15/20
388/388 [==============================] - 293s 755ms/step - loss: 0.5813 - accuracy: 0.7629 - val_loss: 0.6736 - val_accuracy: 0.7206
Epoch 16/20
388/388 [==============================] - 291s 751ms/step - loss: 0.5783 - accuracy: 0.7672 - val_loss: 0.6768 - val_accuracy: 0.7197
Epoch 17/20
388/388 [==============================] - 284s 732ms/step - loss: 0.5746 - accuracy: 0.7685 - val_loss: 0.6830 - val_accuracy: 0.7214
```

9. ارزیابی مدل:

بعد از آموزش مدل، با استفاده از متد evaluate() بر روی داده‌های آزمون، مدل ارزیابی می‌شود. این متد شامل داده‌های متنی پدینگ شده و برچسب‌های احساس مربوطه است و ضرر و دقت مدل را برمی‌گرداند. دقت نسبت نمونه‌های درستاً دسته‌بندی شده در مجموعه آزمون را نشان می‌دهد.

```
# Evaluate the model
loss, accuracy = model.evaluate(test_x, test_y, verbose=0)
print('Accuracy: {:.2f}%'.format(accuracy*100))
```

```
Accuracy: 72.14%
```

10. نمودار کشیدن منحنی‌های دقت و ضرر:

برای نمایش نحوه عملکرد مدل در طول آموزش، منحنی‌های دقت و ضرر با استفاده از شیء history که توسط متد fit() برگشت داده می‌شود، کشیده می‌شوند. دقت آموزش و اعتبارسنجی بر روی یک نمودار و ضرر آموزش و اعتبارسنجی بر روی یک نمودار دیگر نشان

داده می‌شوند. این نمودارها به ما اجازه می‌دهند ببینیم چگونه دقت و ضرر در طول آموزش تغییر کرده‌اند و آیا مدل بیش‌برازش یا کم‌برازش است.

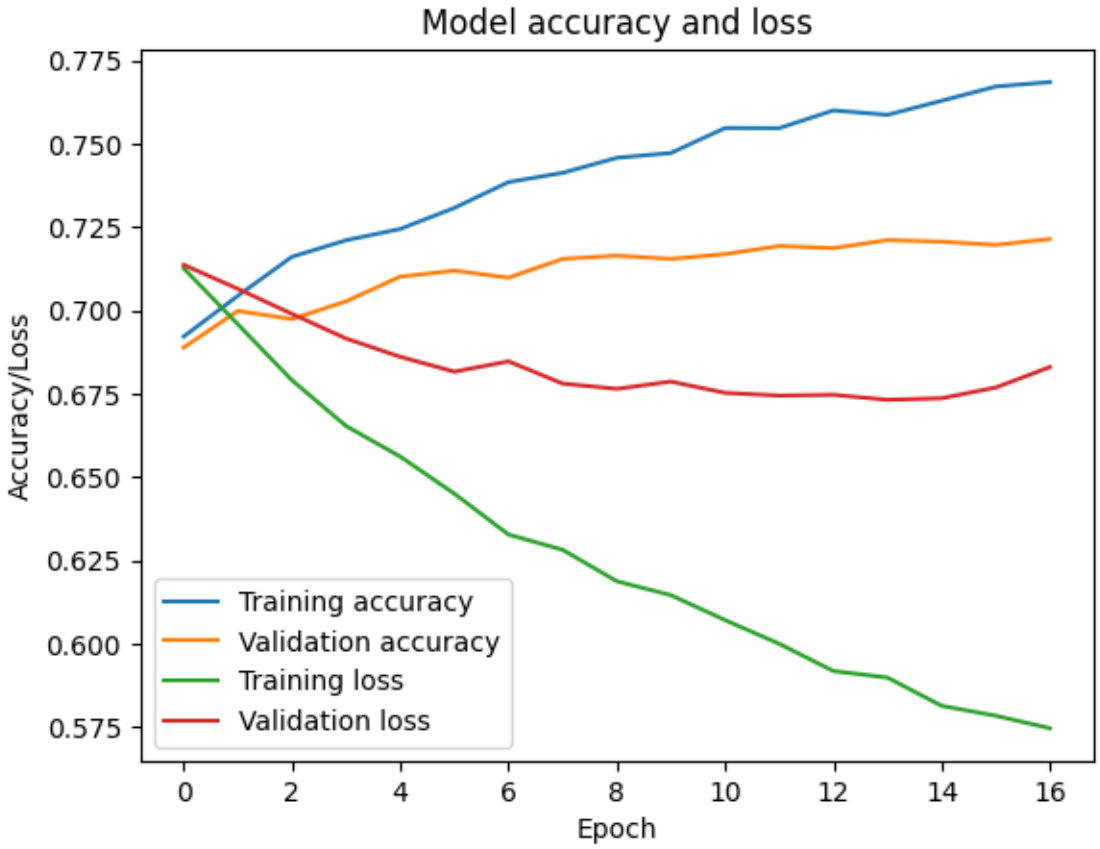

11. پیش‌بینی:

در نهایت، مدل برای پیش‌بینی داده‌های جدید و ناشناخته استفاده می‌شود. تابع predict_sentiment() با دریافت مدل آموزش‌دیده، توکن‌ساز و متن ورودی، برچسب احساسی پیش‌بینی شده را به عنوان یک رشته (منفی=0، بی‌طرف=1، مثبت=2) برمی‌گرداند. سپس از این تابع برای دریافت متن ورودی از کاربر و پیش‌بینی برچسب احساس آن استفاده می‌شود. با پیش‌بینی احساس داده‌های جدید، می‌توانیم با استفاده از مدل تصمیماتی آگاهانه بر اساس احساس متن بگیریم، مانند اینکه آیا به یک شکایت مشتری پاسخ دهیم یا یک نقد مثبت را در رسانه‌های اجتماعی تبلیغ کنیم.

```
# Define function to predict sentiment of input text
def predict_sentiment(model, tokenizer, input_text):
    # Tokenize and pad the input text
    encoded_text = tokenizer.texts_to_sequences([input_text])
    padded_text = pad_sequences(encoded_text, maxlen=200)

    # Predict the sentiment using the trained model
    sentiment_prediction = model.predict(padded_text)

    # Return the predicted sentiment label
    sentiment_dict = {0: 'negative', 1: 'neutral', 2: 'positive'}
    predicted_sentiment = sentiment_dict[np.argmax(sentiment_prediction)]
    return predicted_sentiment

# Take input text from user
while True:
    input_text = input("Enter the text to predict the sentiment: ")

    if input_text == "":
        break
    # Predict the sentiment label of the input text
    predicted_sentiment = predict_sentiment(model, tokenizer, input_text)

    # Print the predicted sentiment label
    print("Predicted sentiment: ", predicted_sentiment)

Enter the text to predict the sentiment: Poor quality material inside.
I've never had or have foot odor except with these shoes. Bought a pair
for my Mom, same thing. Avias used to be great shoes. Would not buy again.
1/1 [==============================] - 0s 322ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: The shoes did not have any
insoles. I received a pair of shoes that were not even completely put
together.
1/1 [==============================] - 0s 49ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: I felt like this product was not
made in a very sturdy way. I would in no way be able to recommend them.
1/1 [==============================] - 0s 99ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: Look nice but that is it.
Everything else failed.
1/1 [==============================] - 0s 87ms/step
Predicted sentiment:  neutral
```

```
Enter the text to predict the sentiment: The fit isn’t right at all and
uncomfortable so I am returning. Bought usual size in sneaker.
1/1 [==============================] - 0s 56ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: Beautiful shows but be advised
they run small. I wear 6.5 in all my other shoes but when I tried these,
my ties hit the end. Unfortunately had to return.
1/1 [==============================] - 0s 49ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: i hate you, but i like you
1/1 [==============================] - 0s 58ms/step
Predicted sentiment:  negative
Enter the text to predict the sentiment: i love you, but i don't like you
1/1 [==============================] - 0s 78ms/step
Predicted sentiment:  positive
```

12. کد و زبان برنامه نویسی:

این سیستم با پایتون 3.9 پیاد سازی و اجرا شده است. دو فایل در خروجی پایتون وجود دارد که یکی به صورت script پایتون و دیگری به صورت یک فایل با پسوند .ipynb که در jupyter notebook یا google_colab قابل اجرا است.

برای اجرای این برنامه نیاز است که موارد زیر نصب باشد:

Pip install pandas

Pip install matplotlib

Pip install numpy

Pip install tensorflow

Pip install sklearn

Pip install google.colab

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
```

```
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout, Embedding,
SpatialDropout1D
from tensorflow.keras.callbacks import EarlyStopping
from tensorflow.keras.optimizers import Adam
from sklearn.model_selection import train_test_split
from google.colab import drive
```

13. منابع:

https://monkeylearn.com/sentiment-analysis/

https://www.qualtrics.com/experience-management/research/sentiment-analysis/

https://www.w3schools.com/python/python_ml_getting_started.asp

https://chat.openai.com/

با تشکر فراوان از جناب آقای دکتر جعفر رزم‌آرا

که مرا در این پروژه راهنمایی کردند.